

Calgary 311 и историски временски податоци

Од временски услови до побарувачка, брзина на затворање и профили на заедници

СТУДЕНТ

ПРЕДМЕТ

СТАТУС

Податочно рударење

Верзија за предавање

1. Цел, податоци и истражувачки дизајн

Проектот користи модели како инструменти за заклучување, не како натпревар на scores.

Целта е да се утврди што може реално да се научи од јавните 311 записи и историското време: колкав дел од дневната snow/ice побарувачка е објаснив, дали можат навреме да се означат екстремни денови, кои информации при поднесување се поврзани со затворање во 7 дена и дали заедниците формираат стабилни профили.

Податоци и аналитички единици

Компонента	Период / единица	Обем	Улога
Snow/ice 311	2018–2025; ден	226,985 барања; 2,919 дена	Q1–Q2
311 closure	2021–2025; групирани барања	2,513,718 барања	Q3
Community × service	2018–2025; заедница	261 подобни заедници	Q4
Open-Meteo ERA5	дневно; една точка	температура, снег, дожд и др.	Q1–Q2

Методолошки избори

- Временска валидација: Q1/Q2 train 2018–2023, validation 2024, test 2025; Q3 train 2021–2023, validation 2024, test 2025. Така се симулира реално идно предвидување [3,4].
- Без leakage: прагови, ретки категории, скалирање, карактеристики и хиперпараметри се определени на train/validation. Test е користен еднаш за финална евалуација.
- Приватност: 311 записите се преземени агрегирано; не се чуваат адреси или точни координати.
- Поврзување: времето е усогласено со локален датум во `America/Edmonton`; ERA5 дава конзистентен reanalysis запис, но не локална причинска мерка [2].

Клучна дефиниција

„Ден со висока побарувачка“ = најмалку 480 барања, односно 95-ти перцентил пресметан само од тренинг-периодот. Таа дефиниција е ретка, оперативно разбирлива и не гледа во идниот test-период.


2. Q1 — Време и дневна snow/ice побарувачка

Цел: објаснување и предвидување на дневниот број барања.

Се споредуваат сезонски baseline, Poisson регресија и Random Forest. MAE е лесно разбирлива во број барања; R^2 го мери објаснетиот дел од варијацијата, а Poisson deviance ја почитува count-природата на целта.

Модел	Test MAE ↓	RMSE ↓	R^2 ↑	Poisson dev. ↓
Сезонски baseline	105.19	139.67	-0.014	137.03
Poisson	67.72	116.34	0.296	88.99
Random Forest	77.75	120.83	0.241	88.23

Test MAE — пониско е подоро



Резултат

Poisson ја намалува MAE за околу 36% наспроти сезонскиот baseline и објаснува околу 30% од test-варијацијата. Најсилни сигнали се годишната сезоналност ('`day_cos`') и просечната температура од претходниот ден; тековната температура и снегот додаваат помал, но јасен сигнал. Spearman корелацијата со задоцнетата температура е -0.658.

Толкување

Пониска температура е поврзана со повеќе snow/ice барања, а одложениот ефект е логичен: граѓаните пријавуваат откако условите ќе се појават и ќе станат видливи. Сепак, $R^2 \approx 0.30$ значи дека времето не е доволно само по себе. Оперативни политики, чистење, ден во неделата, локациски разлики и однесување на граѓаните остануваат надвор од моделот.

Одговор на Q1

Временските услови имаат реална и практично корисна поврзаност со дневната побарувачка, особено сезоната и студот со еднодневно задоцнување. Моделите ја подобруваат прогнозата, но екстремните врвови и најголемиот дел од дневните варијации не се целосно објаснети.


3. Q2 — Невообичаено висока побарувачка

Цел: рано предупредување, при многу ретка позитивна класа.

Во test 2025 само 2.36% од деновите се над прагот (5 дена). Затоа accuracy би била измамна: модел што секогаш предвидува „нормално“ би изгледал добар. Главни мерки се PR-AUC, precision, recall, F1 и balanced accuracy; PR-AUC е особено информативна при силен дисбаланс [5].

Модел	ROC-AUC	PR-AUC	Precision	Recall	Balanced acc.
RF: само време	0.890	0.142	0.093	0.800	0.806
RF: време + календар	0.851	0.128	0.045	1.000	0.742
Logistic: само време	0.784	0.107	0.049	0.800	0.714

Weather-only Random Forest



Резултат и оперативна смисла

Weather-only Random Forest препознава 4 од 5 високи денови, но само околу 9 од 100 аларми би биле вистински. Тоа не е контрадикција: основната стапка е екстремно ниска и мал број false positives брзо ја намалуваат precision. Random Forest е употребен за нелинеарни прагови и интеракции меѓу студ, снег и врнежи [6].

Одговор на Q2

Да, времето може да служи како широка рана тревога со висок recall. Не е доволно за тесно автоматско активирање на ресурси, бидејќи генерира многу лажни тревоги. Практична примена би била дополнителна човечка проверка или комбинирање со оперативни и просторни сигнали.

Несигурност

Заклучокот за 2025 се темели на само пет позитивни денови. Една погрешна класификација го менува recall за 20 процентни поени; затоа метриците мора да се толкуваат како индикативни, не како стабилна гаранција.

4. Q3 и Q4 — Брзина на затворање и профили на заедници

Q3: предвидување во моментот на поднесување

Целта е дали барањето ќе биде затворено во најмногу 7 дена. Predictors се само service name, agency, source и календарски информации достапни при поднесување. Датумот на затворање ја создава целта и не влегува како predictor.

Модел	ROC-AUC	PR-AUC	Precision (slow)	Recall (slow)	F1
Logistic regression	0.925	0.299	0.446	0.355	0.396
Decision tree	0.837	0.197	0.133	0.773	0.227

Логистичкиот модел е подобар за рангирање и precision; дрвото фаќа повеќе бавни случаи со многу повеќе false positives. Најсилни се service/agency. Во 2025 висок удел на бавно затворање имаат „311 Contact Us“ (47.1%), нов signal/light request (45.9%) и sidewalk/curb/gutter repair (27.1%). `Closed` значи административна обработка/идентификуван следен чекор, не нужно физички завршена работа [9].

Одговор на Q3

Да, достапните информации даваат силно рангирање на ризикот, но изборот на праг зависи од трошокот на пропуштен бавен случај наспроти лажна тревога. Моделот опишува процесни разлики меѓу услуги; не треба да се користи за оценување на поединечни граѓани.

Q4: кластери на заедници

Показател	Резултат	Толкување
Избрано k	3	три разбирливи профили
Silhouette	0.282	умерено, не остро разделување [7]
Ward agreement ARI	0.732	добра согласност со друг метод [8]
Temporal ARI	0.411	умерена стабилност низ време

Профилите се: (1) 8 нови/растечки заедници со висока варијабилност; (2) 178 воспоставени и повисоко-обемни заедници со waste/cart mix; (3) 75 урбани/мобилност ориентирани заедници, вклучително Downtown и Beltline. Нормализираниот состав спречува кластерите да бидат само рангирање по големина, но без population denominator интензитетот не е стапка по жител.

Одговор на Q4

Постојат интерпретабилни групи, но тие се описни профили, не природни и непроменливи категории. Умерената временска стабилност бара повторно проценување при нови години или промени во услугите.

5. Синтеза, ограничувања и репродуктивност

Што научивме

Прашање	Краток одговор	Практична импликација
Q1	Умерена поврзаност; студ + сезоналност се главни.	Подобро дневно планирање, но не точна прогноза на врвови.
Q2	Висок recall е возможен, precision останува ниска.	Широк alert со човечка/оперативна потврда.
Q3	Service/agency силно го рангираат ризикот.	Приоритетна проверка на очекувано бавни категории.
Q4	Три корисни, но умерено стабилни профили.	Сегментација за планирање, не фиксна етикета.

Ограничувања

- ERA5 е reanalysis за една градска точка; не ги опфаќа микроклимата и уличните услови.
- Анализата е набљудувачка: асоцијацијата меѓу студ/снег и барања не е причински ефект.
- Промени во 311 политики, канали, класификации и оперативни капацитети можат да создадат concept drift.
- Q2 има само пет позитивни test дена; Q4 нема population denominator и просторна форма.

Репродукција и употреба на LLM

`README.md` ги наведува командите и структурата; `requirements.txt` и `environment.yml` ја фиксираат околината; `work/download\_project\_data.py` ги презема официјалните извори; `work/analyze\_project.py` ја спроведува анализата; Jupyter-тетратката ги поврзува одлуките со резултатите. LLM е користен за планирање, проверка на методологијата, организација на кодот и редакција. Сите бројки се произведени од скриптите и се проверливи; LLM не е извор на емпириски резултати.

Избрана литература и извори

- [1] City of Calgary. Calgary 311 Service Requests. <https://data.calgary.ca/d/iahh-g8bj>
- [2] Open-Meteo. Historical Weather API / ERA5. <https://open-meteo.com/en/docs/historical-weather-api>
- [3] Hyndman, R.J. & Athanasopoulos, G. Forecasting: Principles and Practice, Time-series CV. <https://otexts.com/fpp3/tscv.html>
- [4] Bergmeir, C., Hyndman, R.J. & Koo, B. (2018). A note on the validity of cross-validation for evaluating autoregressive time series prediction. doi:10.1016/j.csda.2017.11.003
- [5] Saito, T. & Rehmsmeier, M. (2015). The precision-recall plot is more informative than ROC for imbalanced data. doi:10.1371/journal.pone.0118432
- [6] Breiman, L. (2001). Random Forests. doi:10.1023/A:1010933404324
- [7] Rousseeuw, P.J. (1987). Silhouettes. doi:10.1016/0377-0427(87)90125-7
- [8] Hubert, L. & Arabie, P. (1985). Comparing partitions. doi:10.1007/BF01908075
- [9] City of Calgary. 311 FAQs: meaning of Closed. <https://www.calgary.ca/311/faqs.html>